DOSSIÊ TÉCNICO & ARQUITETURA DE SOFTWARE

Agente de Código Local e Totalmente Offline

Autor: Rafael Ornelas Tozato

Especialização: Engenheiro Químico | Governança 4.0 | QA & Dados

Tecnologias: OpenCode | Ollama | Qwen3.5 9B | Vercel

Ecossistema: Tozato Dev Hub & TozatoCode-AI

Sumário Executivo: Este documento detalha a implementação de um Agente de Inteligência Artificial para Engenharia de Software operando em modo 100% offline no ambiente local. Combinando o *OpenCode*, o runtime *Ollama* e os pesos abertos do modelo *Qwen3.5 (9B)*, a solução elimina faturas por token e riscos de vazamento de dados confidenciais, mantendo a interoperabilidade com a interface pública de portfólio no Tozato Dev Hub.

1. ARQUITETURA DA SOLUÇÃO & PILARES TÉCNICOS

A arquitetura divide o processamento entre a execução autônoma local e a exibição de interface distribuída:

Componente	Função Principal	Especificação Técnica
OpenCode	Agente de Execução & Edição	Orquestrador terminal que lê repositórios, cria diffs, executa testes e gerencia comandos.
Ollama	Server & API Local	Runtime de inferência local expondo endpoint compatível em `127.0.0.1:11434`.
Qwen3.5 9B	Modelo de Linguagem (LLM)	Modelo de pesos abertos otimizado para Function Calling e Contexto Estendido (64k tokens).
Vercel / GitHub	Interface & Hub Profissional	Hospedagem da Landing Page interativa com botões de acionamento dinâmicos.

2. MÉTRICAS DE PERFORMANCE & DESEMPENHO BENCHMARK

65.6	66.1	65,536
LIVECODEBENCH V6 (QWEN 9B)	BFCL-V4 (FUNCTION CALLING)	JANELA DE CONTEXTO (TOKENS)

3. BENEFÍCIOS DE GOVERNANÇA E PRIVACIDADE

- **Privacidade Absoluta (Zero Leak):** Nenhum trecho de código, chave de API ou propriedade intelectual trafega pela internet ou servidores de terceiros.
- **Previsibilidade Financeira:** Eliminação completa do custo marginal por token em chamadas comerciais (OpenAI/Anthropic).
- **Continuidade Operacional:** Garantia de produtividade em cenários de instabilidade de rede, viagens ou ambientes fabris/isolados.

4. GUIA EXECUTIVO DE IMPLANTAÇÃO DO SERVIDOR OFFLINE

Para inicializar o servidor de IA local sem chamadas externas e com suporte a contexto estendido, execute os comandos abaixo no terminal:

```
# 1. Download do modelo otimizado (Executar uma vez conectado) ollama pull qwen3.5:9b # 2. In
icialização do servidor 100% isolado (Modo Offline) OLLAMA_HOST=127.0.0.1:11434 OLLAMA_NO_CLOUD=1 O
LLAMA_CONTEXT_LENGTH=65536 ollama serve
```

5. CONFIGURAÇÃO DO PROJETO OPENCODE (OPENCODE.JSON)

Arquivo de parâmetros para vinculo do agente local:

```
{ "model": "qwen3.5:9b", "small_model": "qwen3.5:9b", "baseURL": "http://127.0.0.1:11434/v1",
"tools": { "web_search": false } }
```

6. INTEGRAÇÃO COM O TOZATO DEV HUB & PORTFÓLIO

A aplicação publica no ar através da Vercel (`tozato-dev-hub.vercel.app`) atua como a vitrine profissional interativa. Ela centraliza a navegação pelos botões de acesso a certificações e repositórios oficiais, ao mesmo tempo em que disponibiliza toda a arquitetura de código para ser clonada e executada offline por engenheiros e recrutadores.

> **Matriz de Requisitos de Hardware para Execução Local:**
>
> - **RAM Mínima do Sistema:** 16 GB (Recomendado 24GB+ para contexto de 64k).
> - **Espaço em Disco:** ~7.5 GB para armazenar os pesos do modelo Qwen3.5 9B.
> - **Compatibilidade:** macOS, Linux e Windows (WSL2).

7. CONEXÕES PROFISSIONAIS & CANAIS DE CONTATO

Acesse os canais oficiais para acompanhar outros projetos em Governança 4.0, Automação de Testes e Inteligência Artificial:

- **GitHub Oficial:** github.com/Rafael-TOZATO
- **LinkedIn Profissional:** linkedin.com/in/rafaeltozato81
- **Medium (Artigos Técnicos):** medium.com/@ornelas.tozato
- **Tozato Dev Hub:** tozato-dev-hub.vercel.app